

INSTITUT DE FORMATION AUX
NORMES ET TECHNOLOGIES
DE L'INFORMATIQUE
SOKODE

Traitement de Données Semi-Structurées

XML et DTD

Mouhamam Sani KOUMOI

IFNTI S2

06 Mars 2024

Table des matières

1. Introduction
   - Origine
   - Base du langage XML
2. Le langage XML
   - Structure générale
   - Déclarations
   - Arbre d'élément
   - Bonne formation et validité
3. Validité d'un document : DTD
   - Généralités
   - Contenu

Origine du langage XML

XML : eXtensible Markup Language

- Standard développé par le W3C (World Wide Web Consortium)
- Forme extensible de HTML : définition de balises là où HTML ne fait qu'utiliser des balises
- Peut être utilisé sur le Web

Trois aspects pour un même document

Un document = Trois (3) aspects différents

- Le contenu (le fond)
- La structure logique
- La présentation (la forme)

Séparation de ces trois (3) aspects

- Contenu = fichier XML
- Structure logique = DTD interne ou externe
- Présentation = CSS, XSL

Structure logique arborescente d'un document XML

Déclarations

1. Déclaration XML (version, type, encodage)
2. Déclarations de types (DTD)
3. Instructions de traitement (CSS, XSL)

Arbre d'éléments ordonnés

1. Même principe que HTML
   - Éléments (ou nœuds)
   - Attributs
   - Valeurs littérales
2. Arbre conforme à la DTD
3. Présentation déléguée

Déclaration XML

Balise générique

<? xml version="1.0" [encoding="nom_encodage"] [standalone="yes|no"]? >

Structure de la balise <?xml ? >

- Les points d'interrogation et le mot xml sont obligatoires
- L'attribut version indique la version de la norme XML utilisée pour le document
- L'attribut encoding indique l'encodage de caractères utilisé dans le document
- L'attribut standalone indique la présence ou non de références externes (DTD interne ou externe)

Déclaration de types

Balise générique

<!DOCTYPE element-racine [Info-DTD|Declarations internes] >

Structure de la balise <!DOCTYPE >

- L'élément racine est l'élément qui englobe tous les autres
- La DTD (Document Type Definition) d'un document XML définit la grammaire d'un document XML
  - Elle décrit la structure du document XML
  - Elle permet la validation du document grâce à sa grammaire
  - Elle est interne (au sein du fichier XML, avec déclarations internes) ou externe (dans un fichier .dtd, avec Info-DTD)
  - Si elle est externe, Info-DTD devient SYSTEM (DTD disponible localement) ou PUBLIC (DTD publiée sur internet)

Construction de l'arbre d'élément

Contraintes syntaxiques

1. Un document possède une et une seule racine
2. Les éléments :
   - sont encadrants (balises ouvrante/fermante) ou auto-fermants
   - doivent être imbriquées
   - peuvent avoir 0, 1 ou plusieurs attributs
3. Un nom d'élément :
   - doit commencer par une lettre ou un '-'
   - peut comporter des chiffres, des lettres, '-', '.' ou '_'
   - peut posséder un nom de domaine : "nomDeDomaine :nomElement"
   - est sensible à la casse
4. Les attributs d'un élément :
   - donnent des précisions sur les éléments et sur leur contenu
   - doivent avoir un nom et une valeur
   - ne sont pas sensibles à l'ordre

Suppléments d'informations sur la syntaxe XML

Commentaires

<! – – Ceci est un commentaire – – >

Caractères spéciaux

Certains caractères sont utilisés dans la syntaxe du langage. Pour les considérer tels quels, il faut les échapper :
< = &lt ; > = &gt ; ' = &apos ; " = &quot ; & = &amp

CDATA

L'utilisation de CDATA permet d'indiquer à l'analyseur de ne pas tenir compte du balisage, par exemple lorsque l'on veut inclure du code dans les balises :
<![CDATA [Text brute non lu par l'analyseur]]>

Vocabulaire général

Document XML bien formé

Un document XML est bien formé s'il respecte la syntaxe XML :

- Il contient un ou plusieurs éléments
- Un seul élément contient tous les autres (racine)
- Les éléments sont correctement imbriqués
- Les balises de début et fin correspondent (casse comprise)
- Les noms d'attributs sont uniques par élément
- Les valeurs d'attributs sont entre " ou '
- Les entités sont déclarées avant d'être utilisées

Document XML valide

Un document XML est valide s'il se conforme à sa DTD.

Définition

Document Type Definition

- La DTD définit les éléments et leurs règles d'utilisation (noms des éléments, attributs possibles pour un élément, imbrications). Il s'agit d'un modèle de document XML
- Si un document suit les règles définies par XML, il est bien formé
- Si un document est bien formé et qu'il fait référence à une DTD à laquelle il est conforme, il est valide.
- Ni la DTD, ni le document XML ne contiennent d'information concernant l'affichage, c'est la CSS qui définira la présentation.

Utilité

A quoi sert une DTD ?

1. La DTD est la définition de la grammaire d'un document XML
2. Elle décrit les éléments
   - Noms de balises autorisées
   - Ordre et imbrication des balises
   - Caractère optionnel des éléments
3. Elle décrit les attributs pour chaque élément
   - Noms des attributs autorisés
   - Caractère optionnel ou obligatoire des attributs
   - Types des attributs
   - Valeurs par défaut

Déclaration DTD

Dans le document XML : 3 types de déclarations

- DTD interne
  <!DOCTYPE racine [declarations internes]>
- DTD externe locale
  <!DOCTYPE racine SYSTEM "fichier.dtd">
- DTD externe publique
  <!DOCTYPE racine PUBLIC "nomConnu" "URL">

Contenu d'une DTD

Déclaration d'élément et d'attribut (ordre pas important)

- Déclaration d'élément :
  <!ELEMENT nom_balise (contenu)>
- L'ordre des sous-éléments est important et spécifié dans (contenu)
- Déclarations des attributs d'un élément :
  <!ATTLIST element attribut type value>

Exemple

<!ELEMENT auteur (nom,prenom,initial)>
<!ATTLIST auteur decore (oui|non) "non">

Déclaration d'élément (1/2)

Syntaxe générale

<!ELEMENT nomElement EMPTY|ANY|(modeleContenu)>
Ainsi, 3 possibilités de contenu pour l'élément :

- Soit il est vide (EMPTY)
- Soit il contient n'importe quel élément déclaré de la DTD (ANY)
- Soit il est formaté selon un modèle (modeleContenu)

Déclaration d'élément (2/2)

Les modèles de contenu

- Si uniquement des données :
  <!ELEMENT nomElement (#PCDATA)>
- Si uniquement d'autres éléments :
  <!ELEMENT nomElement (element1,element2,...)>
  <!ELEMENT nomElement
  (element1+,element2(étoile),element3 ?)>
  <!ELEMENT nomElement (element1 | element2 |...)>

Significations des symboles utilisés

- | : Ou logique
- ? : 0 ou 1
- + : Au moins 1
- étoile : 0 ou plusieurs

Déclaration d'attribut (1/2)

Syntaxe générale

<!ATTLIST element attribut type value>

Les valeurs possibles (en remplacement de value)

- une valeur par défaut entre guillemets simples ' ou doubles "
- #REQUIRED : valeur d'attribut obligatoire
- #IMPLIED : valeur d'attribut optionnelle
- #FIXED 'valeur' : valeur d'attribut fixée

Déclaration d'attribut (2/2)

Principaux types d'attribut (en remplacement de type)

- CDATA : données textuelles ne contenant pas de balises XML
- (valeur1|valeur2|...|valeurN) : liste de valeurs possibles
- ENTITY : entité déclarée dans la DTD
- NOTATION : notation déclarée dans la DTD
- ID : l'attribut possède une valeur unique pour chaque élément
- IDREF : l'attribut se réfère à un ID d'un autre attribut
- IDREFS : l'attribut peut se référer à plusieurs ID, chaque valeur étant séparée par un espace